HI CS353 Linux内核大作业报告

517030910214 刘宏洲

H2 0. 简介

在本作业中,我们实现了进程页面热度的收集与展示。主要实现了一个模块,用于过滤指定进程的数据页面、采集热度信息,并且实现了热度信息在内核态与用户态之间的共享。

本大作业的系统环境配置如下:

- Ubuntu 18.04.4 LTS (GNU/Linux 5.5.8 x86_64)
- GNU Make 4.1
- gcc 7.5.0

H2 1. 过滤页面

H3 1.1 实现

首先,我们需要过滤掉与进程内数据无关的页面。由于我们首先获取的是进程的VMA结构体,我们可以根据VMA的特征来判断一个VMA所包含的所有页面是否为包含数据的页面。在linux/mm types.h 中定义的 mm struct 结构体中的一些数据成员引起了我的注意:

```
1 unsigned long total_vm; /* Total pages mapped */
2 unsigned long locked_vm; /* Pages that have PG_mlocked set */
3 atomic64_t pinned_vm; /* Refcount permanently increased */
4 unsigned long data_vm; /* VM_WRITE & ~VM_SHARED & ~VM_STACK */
5 unsigned long exec_vm; /* VM_EXEC & ~VM_WRITE & ~VM_STACK */
6 unsigned long stack_vm; /* VM_STACK */
```

根据注释和变量名,我们知道,这些数据成员统计了一个内存描述符所管理的各种类型的VMA数量。而 data_vm 正是包含数据的VMA的数量,其注释告诉我们,可以利用这个特征过滤出包含数据的所有VMA。因此,过滤页面的代码如下:

```
1 static int filter_page(pid_t pid)
 2 {
 3
    struct pid *p;
 4 struct task_struct *tsk;
    struct vm_area_struct *cur;
 5
 6
      unsigned long filtered_num, addr;
 7
      if (pid < 0)
 8
 9
10
        printk(KERN_ERR "Invalid PID\n");
11
      return -EFAULT;
12
13
14
      p = find_get_pid(pid);
15
16
      if (!p)
17
        printk(KERN_ERR "Invalid pid\n");
18
19
        return -EFAULT;
20
```

```
21
22
      tsk = get_pid_task(p, PIDTYPE_PID);
23
24
      if (!tsk)
25
      {
26
        printk(KERN_ERR "Invalid task_struct\n");
        return -EFAULT;
27
28
      }
29
      if (!tsk->mm)
30
31
      {
        printk(KERN_ERR "task_struct->mm is NULL\n");
32
33
        return -EFAULT;
34
      }
35
36
      cur = tsk->mm->mmap;
37
      filtered_num = 0;
38
      heat info len = 0;
39
      while (cur)
40
41
42
        if (cur->vm_flags & (VM_WRITE & ~VM_SHARED & ~VM_STACK))
43
44
          printk(KERN_INFO "FILTERED: 0x%lx\t0x%lx\n", cur->vm_start, cur-
    >vm_end);
45
          for (addr = cur->vm_start; addr < cur->vm_end; addr += PAGE_SIZE)
46
47
            heat_info[heat_info_len + 1].addr = addr;
            heat_info[heat_info_len + 1].access_time = 0;
48
49
            heat_info_len++;
50
          }
51
          filtered_num += vma_pages(cur);
52
        }
53
        cur = cur->vm_next;
54
55
      heat_info[0].addr = 0;
56
      heat_info[0].access_time = filtered_num;
57
      if (is_show_malloc)
        printk(KERN_INFO "total: %ld, filtered: %ld, malloc: %ld\n", tsk->mm-
58
    >total_vm, filtered_num, malloc_num);
59
      else
60
        printk(KERN_INFO "total: %ld, filtered: %ld\n", tsk->mm->total_vm,
    filtered_num);
61
62
      return 0;
63 }
```

首先调用 find_get_pid 以及 get_pid_task ,从进程PID获得进程的 task_struct ,从而找到进程的 vm_area_struct 。随后,遍历 vm_area_struct 链表,根据条件过滤页面,并将页面的信息存入 heat_info 数组中,置访问次数为0。为了方便后续与用户态的信息传递,将过滤所得数据页面总数存入数组的第一个元素中。在这里,我们假定一个进程的VMA链表在短时间内是不发生改变的。这方便了后续热度信息的收集。

H3 1.2 结果

我们对提供的 heat_cpp 与 heat_rand.cpp 进行一定的修改,并利用这两个程序来展示这个部分的实验结果。

使用以下命令,便可观察输出(只展示heat.cpp的结果)

- 1 ./heat 10
- 2 dmesg

```
[20936.355876] filter PID: 15986
                                           0×560ab6030000
[20936.355880] FILTERED: 0×560ab6568000
                                           0×560abb5c7000
                                           0×7fb075013000
[20936.355942] FILTERED: 0×7fb07c000000
                                           0×7fb07d013000
[20936.355954] FILTERED: 0×7fb080000000
                                           0×7fb081013000
[20936.355964] FILTERED: 0×7fb084000000
                                           0×7fb085013000
[20936.355975] FILTERED: 0×7fb088000000
                                           0×7fb089013000
[20936.355986] FILTERED: 0×7fb08c000000
                                           0×7fb08d013000
                                           0×7fb091013000
[20936.356008] FILTERED: 0×7fb094000000
                                           0×7fb097ff9000
[20936.356052] FILTERED: 0×7fb09c000000
                                           0×7fb09fff9000
[20936.356098] FILTERED: 0×7fb0a4000000
                                           0×7fb0a7ff9000
[20936.356141] FILTERED: 0×7fb0ac000000
                                           0×7fb0afff9000
[20936.356187] FILTERED: 0×7fb0b4000000
                                           0×7fb0b7ff9000
[20936.356233] FILTERED: 0×7fb0bc000000
                                           0×7fb0bfff9000
[20936.356285] FILTERED: 0×7fb0c4000000
                                           0×7fb0c7ff9000
[20936.356339] FILTERED: 0×7fb0cb23f000
                                           0×7fb0cba3f000
[20936.356346] FILTERED: 0×7fb0cba40000
                                           0×7fb0cc240000
[20936.356353] FILTERED: 0×7fb0cc241000
                                           0×7fb0cca41000
[20936.356360] FILTERED: 0×7fb0cca42000
                                           0×7fb0cd242000
20936.356367] FILTERED: 0×7fb0cd243000
                                           0×7fb0cda43000
[20936.356374] FILTERED: 0×7fb0cda44000
                                           0×7fb0ce244000
[20936.356380] FILTERED: 0×7fb0ce245000
                                           0×7fb0cea45000
[20936.356389] FILTERED: 0×7fb0cec4c000
                                           0×7fb0cec4d000
[20936.356391] FILTERED: 0×7fb0cee60000
                                           0×7fb0cee61000
[20936.356391] FILTERED: 0×7fb0cee61000
                                           0×7fb0cee62000
                                                                 图1. 筛选页面
[20936.356393] FILTERED: 0×7fb0cf067000
                                           0×7fb0cf068000
[20936.356394] FILTERED: 0×7fb0cf26b000
                                           0×7fb0cf26c000
[20936.356395] FILTERED: 0×7fb0cf493000
                                           0×7fb0cf494000
[20936.356396] FILTERED: 0×7fb0cf7c8000
                                           0×7fb0cf7cc000
[20936.356398] FILTERED: 0×7fb0cfa61000
                                           0×7fb0cfa62000
[20936.356398] FILTERED: 0×7fb0cfa62000
                                           0×7fb0cfa82000
[20936.356400] FILTERED: 0×7fb0cfc92000
                                           0×7fb0cfc93000
[20936.356401] FILTERED: 0×7fb0cfc93000
                                           0×7fb0cfcb3000
[20936.356402] FILTERED: 0×7fb0cfeb6000
                                           0×7fb0cfeb7000
[20936.356403] FILTERED: 0×7fb0d00ce000
                                           0×7fb0d00cf000
[20936.356404] FILTERED: 0×7fb0d0359000
                                           0×7fb0d035a000
                                           0×7fb0d035b000
20936.356406] FILTERED: 0×7fb0d0746000
                                           0×7fb0d0748000
20936.356407] FILTERED: 0×7fb0d0748000
                                           0×7fb0d074c000
20936.356408] FILTERED: 0×7fb0d0966000
                                           0×7fb0d0967000
[20936.356408] FILTERED: 0×7fb0d0967000
                                           0×7fb0d096b000
[20936.356409] FILTERED: 0×7fb0d0b99000
                                           0×7fb0d0b9a000
[20936.356410] FILTERED: 0×7fb0d0f37000
                                           0×7fb0d0f38000
[20936.356411] FILTERED: 0×7fb0d12bb000
                                           0×7fb0d12bd000
[20936.356411] FILTERED: 0×7fb0d12bd000
                                           0×7fb0d12c1000
[20936.356412] FILTERED: 0×7fb0d1550000
                                           0×7fb0d1551000
[20936.356413] FILTERED: 0×7fb0d1551000
                                           0×7fb0d1556000
[20936.356414] FILTERED: 0×7fb0d1743000
                                           0×7fb0d174d000
[20936.356414] FILTERED: 0×7fb0d177b000
                                           0×7fb0d177d000
[20936.356415] FILTERED: 0×7fb0d177e000
                                           0×7fb0d177f000
[20936.356416] FILTERED: 0×7fb0d177f000
                                           0×7fb0d1780000
[20936.356417] FILTERED: 0×7ffde4a46000
                                           0×7ffde4a67000
```

由于终端显示的行数有限,我截取了 /var/log/kern.log 中的内容,可见,筛选出的页面 总数为申请页面总数的109%,说明这样的筛选策略是有效的。

```
before: 0×560ab65a3f80 0×560ab65e3f80
after: 0×560ab65abf90 0×560ab65ebf90
before: 0×7fb0c4000b20 0×7fb0c4040b20
after: 0×7fb0c4008b30 0×7fb0c4048b30
before: 0×560ab65b4fb0 0×560ab65f4fb0
after: 0×560ab65bcfc0 0×560ab65fcfc0
before: 0×7fb0c4010b40 0×7fb0c4050b40
after: 0×7fb0c4018b50 0×7fb0c4058b50
before: 0×7fb0bc000b20 0×7fb0bc040b20
after: 0×7fb0bc0008b30 0×7fb0bc048b30
```

图2. 申请页面

除此之外,我们观察用户态申请的二维数组中,部分一维数组的起始地址与结束地址,如图2。我们会发现,这些地址都包含在筛选出的VMA中,并且,每一个一维数组的起始地址与页面起始地址都不相同。例如图中的第一个数组的起始地址为0x560ab65a3f80,而它所在的页面起始地址应当为0x560ab65a3000。

H2 2. 收集页面热度

H3 2.1 实现

得到了过滤后的页面,就可以开始统计热度信息了。统计热度信息的实现如下:

```
1 static int collect_heat(pid_t pid)
 2 {
 3 struct pid *p;
 4
      struct task struct *tsk;
 5
      pte_t *pte;
 6
      int i;
 7
      ktime t calltime, delta, rettime;
      unsigned long long duration;
 8
 9
10
      if (pid < 0)
11
12
        printk(KERN ERR "Invalid PID\n");
13
        return -EFAULT;
14
      }
15
16
      p = find_get_pid(pid);
17
18
      if (!p)
19
20
        printk(KERN_ERR "Invalid pid\n");
21
       return -EFAULT;
22
      }
23
24
      tsk = get_pid_task(p, PIDTYPE_PID);
25
```

```
26
      if (!tsk)
27
      {
28
        printk(KERN_ERR "Invalid task_struct\n");
29
        return -EFAULT;
30
      }
31
32
      if (!tsk->mm)
33
      {
34
        printk(KERN_ERR "task_struct->mm is NULL\n");
35
        return -EFAULT;
36
      }
37
38
      calltime = ktime_get();
39
       for (i = 0; i < heat_info_len; ++i)</pre>
40
41
        pte = _find_pte(tsk->mm, heat_info[i + 1].addr);
42
        if (!pte)
43
        {
44
          continue;
45
46
        if (pte_young(*pte))
47
          heat info[i + 1].access time += 1;
48
49
           *pte = pte_mkold(*pte);
50
        }
51
      }
52
       rettime = ktime_get();
53
      delta = ktime_sub(rettime, calltime);
54
       duration = (unsigned long long)ktime_to_us(delta);
55
       printk(KERN_INFO "Heat collection elapsed after %lld us\n", duration);
       return 0;
56
57 }
```

可见,同第一部分一样,要调用 find_get_pid 以及 get_pid_task 获得 task_struct。随后遍历之前过滤得到的所有数据页面,并将页面的虚拟地址转化为对应的页表项 pte。随后调用 pte_young 判断在上一个时间段中,这个页面是否被访问。若被访问过,则需要统计累计访问信息,并调用 pte_mkold 清空所有标志位。值得注意的是, pte_mkold 并不会改变原有表项的值,而是返回一个新的 pte,因此,我们需要将返回值写入这个 pte 中,完成更新。注意,有的页面虚拟地址对应的 pte 并不存在(没有数据存在),因此我们需要判断并跳过这些虚拟地址。转换虚拟地址到 pte 的函数如下:

```
static inline pte_t* _find_pte(struct mm_struct *mm, unsigned long addr)
 1
 2 {
 3
      pgd_t *pgd = NULL;
      p4d_t *p4d = NULL;
 4
 5
      pud_t *pud = NULL;
      pmd_t *pmd = NULL;
 6
 7
      pte_t *pte = NULL;
 8
9
      pgd = pgd_offset(mm, addr);
      if(pgd_none(*pgd) || pgd_bad(*pgd))
10
       return NULL;
11
```

```
12
13
      p4d = p4d_offset(pgd, addr);
      if(p4d_none(*p4d) || p4d_bad(*p4d))
14
15
      return NULL;
16
      pud = pud_offset(p4d, addr);
17
      if(pud_none(*pud) || pud_bad(*pud))
18
19
      return NULL;
20
      pmd = pmd_offset(pud, addr);
21
      if(pmd_none(*pmd) || pmd_bad(*pmd))
22
23
      return NULL;
24
      pte = pte_offset_map(pmd, addr);
25
      if(pte none(*pte) ||!pte present(*pte))
26
27
       return NULL;
28
      return pte;
29 }
```

H3 2.2 结果

为了更好地测算收集热度所耗费的时间,我们将收集和信息打印分为两个函数实现,通过用户态写入/proc/heat 文件的信息调用这两个函数。打印信息的函数实现非常简单

```
1  static void print_info(void)
2  {
3    int i;
4    for (i = 0; i < heat_info_len; ++i)
5    {
6       printk(KERN_INFO "PAGE: 0x%lx\theat: %d\n", heat_info[i + 1].addr,
      heat_info[i + 1].access_time);
7    }
8 }</pre>
```

再此基础上,再次运行 heat.cpp 与 heat_rand.cpp (输入参数与第一部分一致),我们可以在内核日志中看到获得的热度信息结果。由于一次打印将会输出约17万行,我们只在用户态程序的最后一个循环结束后打印热度信息。在 /var/log/kern.log 中的输出以及用户态的输出如下:

```
[20936.482031] collect PID: 15986
[20936.568153] Heat collection elapsed after 2224 us
[20936.568153] Heat collection elapsed after 2221 us
[20936.667402] collect PID: 15986
[20936.673863] collect PID: 15986
[20936.738630] collect PID: 15986
[20936.738630] collect PID: 15986
[20936.830370] collect PID: 15986
[20936.830370] collect PID: 15986
[20936.830370] collect PID: 15986
[20936.830370] collect PID: 15986
[20936.902680] Heat collection elapsed after 2220 us
[20936.902680] Heat collection elapsed after 2273 us
[20936.90387] collect PID: 15986
[20936.981265] Heat collection elapsed after 2295 us
[20937.966284] collect PID: 15986
[20937.966284] collect PID: 15986
[20937.966284] collect PID: 15986
[20937.966284] elat collection elapsed after 2252 us
[20937.706440] Heat collection elapsed after 2252 us
[20937.706440] Heat collection elapsed after 2254 us
[20937.729173] collect PID: 15986
[20937.729173] collect PID: 15986
[20937.729173] collect PID: 15986
[20937.729173] collect PID: 15986
[20937.729187] collect PID: 15986
[20937.7368474] collect PID: 15986
```

图3. 收集热度(部分输出)

可见,收集约170000个页面热度信息所需的时间约为3ms,相对于访问密集型程序的计算时间来说还是比较小的。最终,经历了100个循环后的部分热度信息输出如下:

[20944.188669]	PAGE:	0×560ab602f000	heat:	100
[20944.188670]	PAGE:	0×560ab6568000	heat:	1
[20944.188670]	PAGE:	0×560ab6569000	heat:	0
[20944.188670]	PAGE:	0×560ab656a000	heat:	0
[20944.188671]	PAGE:	0×560ab656b000	heat:	0
[20944.188671]	PAGE:	0×560ab656c000	heat:	0
[20944.188672]	PAGE:	0×560ab656d000	heat:	0
[20944.188672]	PAGE:	0×560ab656e000	heat:	0
[20944.188673]	PAGE:	0×560ab656f000	heat:	0
[20944.188673]	PAGE:	0×560ab6570000	heat:	1
[20944.188674]	PAGE:	0×560ab6571000	heat:	0
[20944.188674]	PAGE:	0×560ab6572000	heat:	0
[20944.188675]	PAGE:	0×560ab6573000	heat:	0
[20944.188675]	PAGE:	0×560ab6574000	heat:	0
[20944.188675]	PAGE:	0×560ab6575000	heat:	0
[20944.188676]	PAGE:	0×560ab6576000	heat:	0
[20944.188676]	PAGE:	0×560ab6577000	heat:	0
[20944.188677]	PAGE:	0×560ab6578000	heat:	0
[20944.188677]	PAGE:	0×560ab6579000	heat:	0
[20944.188678]	PAGE:	0×560ab657a000	heat:	100
[20944.188678]	PAGE:	0×560ab657b000	heat:	100
[20944.188679]	PAGE:	0×560ab657c000	heat:	100
[20944.188679]	PAGE:	0×560ab657d000	heat:	100
[20944.188679]	PAGE:	0×560ab657e000	heat:	100
[20944.188680]	PAGE:	0×560ab657f000	heat:	100
[20944.188680]	PAGE:	0×560ab6580000	heat:	100
[20944.188681]	PAGE:	0×560ab6581000	heat:	100
[20944.188681]	PAGE:	0×560ab6582000	heat:	100
[20944.188682]	PAGE:	0×560ab6583000	heat:	100
[20944.188682]	PAGE:	0×560ab6584000	heat:	100
[20944.188683]	PAGE:	0×560ab6585000	heat:	100
[20944.188683]	PAGE:	0×560ab6586000	heat:	100
[20944.188684]	PAGE:	0×560ab6587000	heat:	100
[20944.188684]	PAGE:	0×560ab6588000	heat:	100
[20944.188685]	PAGE:	0×560ab6589000	heat:	100
[20944.188685]	PAGE:	0×560ab658a000	heat:	100

图4. 热度信息

H2 3.与用户态交互

H3 3.1 实现

与用户态程序的交互分为两部分,一部分是用户态将命令写入/proc/heat 文件,触发相应功能,另一部分是用户态读取共享在/proc/heat 中的热度信息并输出。

proc文件系统中文件定义的各种操作不再叙述。写函数的定义也很简单,并且已经在之前两个部分实现了:

```
1 static ssize_t getHeat_proc_write(struct file *file, const char __user *buffer,
     size_t count, loff_t *data)
 2 {
 3
   int pid;
 4
      int ret;
 5
      if (copy_from_user(proc_buf, buffer, count))
 6
 7
        printk(KERN_ERR "Copy from user unfinished\n");
 8
        return -EFAULT;
 9
      proc_buf[count] = '\0';
10
11
12
      if (strncmp(proc_buf, "filter", 6) == 0)
13
14
        sscanf(proc_buf + 7, "%d", &pid);
15
        printk(KERN_INFO "filter PID: %d\n", pid);
        ret = filter_page(pid);
16
17
      }
      else if (strncmp(proc_buf, "collect", 7) == 0)
18
19
20
        sscanf(proc_buf + 8, "%d", &pid);
21
        printk(KERN_INFO "collect PID: %d\n", pid);
22
        ret = collect_heat(pid);
23
      }
24
      else if (strncmp(proc_buf, "malloc", 6) == 0)
25
26
        sscanf(proc_buf + 7, "%d %ld", &is_show_malloc, &malloc_num);
27
      else if (strncmp(proc_buf, "print", 5) == 0)
28
29
      {
30
        print_info();
31
      }
32
      else
33
34
        printk(KERN_ERR "Invalid input!\n");
35
      }
36
37
      return count;
38 }
```

这里的命令分为以下四种

- 1. filter PID: 过滤给定PID对应进程的数据页面
- 2. collect PID: 在过滤的基础上,收集给定PID对应进程的页面热度信息
- 3. malloc 0/1 size : 是否(0/1) 打印用户态程序所分配的页面数
- 4. print: 内核态打印热度信息

由于需要在用户态的程序中输出热度信息,我们需要通过proc文件系统共享 heat_info数组,并通过自定义读函数来实现用户态的热度信息输出。这部分内核态的实现也很简单

可以直接将 heat_info 复制到用户空间的缓冲区去,然后在用户态程序中声明同样的结构体以及数组,使用读文件函数即可获得这些信息。

我们将 heat.cpp 以及 heat_rand.cpp 进行修改。首先,将获取、打印热度信息与原有计算函数 heat() 分为两个线程。即

```
1 int main(int argc, char *argv[]){
 2
   pthread_t id;
 3 int ret;
 4
     ret = pthread_create(&id, NULL, &collect, NULL);
 5
 6
     if (ret == 0)
7
8
      printf("-----Start heat collection------
    \n");
9 }
10 else
11
12
     printf("Start collection failed!\n");
     return 0;
13
14
     }
15
16
     heat();
17
18
     return 0;
19 }
```

在 heat()函数中,使之每计算5个循环休眠一定时间。 collect 线程的实现如下:

```
1 void* collect(void* args)
 2 {
 3 int f, i, c, actual_len;
      char write_info[100];
 4
 5
      // char read_info[5000000];
 6
 7
      sleep(1);
 8
9
      f = open("/proc/heat", O_RDWR | O_TRUNC);
10
      ftruncate(f, 0);
11
12
      lseek(f, 0, SEEK_SET);
```

```
sprintf(write_info, "malloc 0 0");
13
14
      write(f, write_info, strlen(write_info));
15
      ftruncate(f, 0);
16
      lseek(f, 0, SEEK_SET);
17
      sprintf(write_info, "filter %d", getpid());
18
      write(f, write_info, strlen(write_info));
19
20
21
      for (c = 0; c < 50; ++c)
22
23
      ftruncate(f, 0);
       lseek(f, 0, SEEK_SET);
24
       sprintf(write_info, "collect %d", getpid());
25
26
       write(f, write_info, strlen(write_info));
       read(f, read_info, sizeof(read_info));
27
28
       actual_len = read_info[0].access_time;
        printf("-----\n", c);
29
30
       for (i = 1; i <= actual len; ++i)
31
         if(read_info[i].access_time > 0)
32
           printf("PAGE: 0x%lx\tHEAT: %d\n", read_info[i].addr,
33
    read_info[i].access_time);
34
       }
        printf("-----\n", c);
35
36
        usleep(50000);
37
     }
38
      close(f);
39 }
```

首先需要等待 heat() 函数初始化完毕,然后打开 /proc/heat 文件,并进行页面过滤。随后执行50次热度收集与打印。每一次打印完毕后,需要睡眠一定时间,让 heat() 进行一定的计算。而这个睡眠时间是人为设定的,必须要恰当地设置,使得 heat() 函数返回后 collect() 函数才返回。这样就完成了内核态和用户态之间热度信息的传递。

H3 3.2 结果

直接运行benchmark中的两个程序(输入参数为10)即可观察热度信息的打印。由于 收集一次热度信息输出的字符太多(约300万个),如果在终端使用 printf 输出,会花费大 量时间,需要调整 heat 线程的睡眠时间,于是我将输出重定向至 res 文件中,以下是输出的 结果:

图5. 用户态输出(部分)

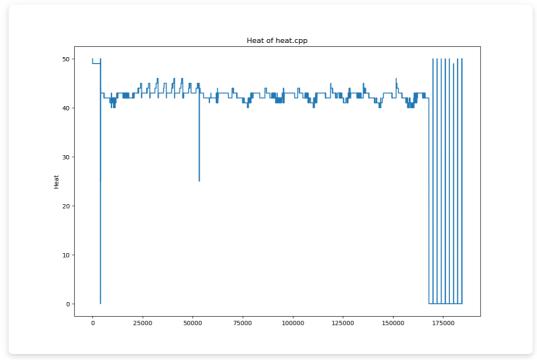


图6. heat.cpp 热度分布

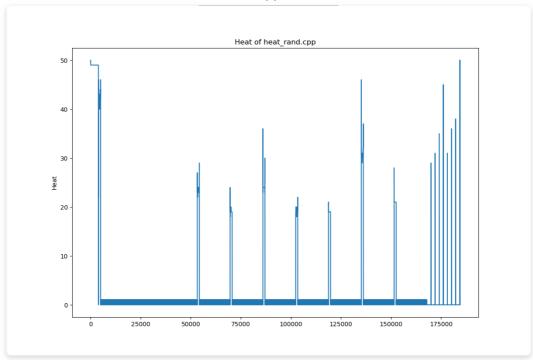


图7. heat_rand.cpp 热度分布

由此可见,heat.cpp对于数据的访问频次比较均匀,而heat_rand.cpp对数据的访问主要集中在某几个地址。至于高地址部分,两个程序都出现了密集的波峰,这可能是因为数据页面在这一部分的分布比较分散。

H2 4. 总结

在本大作业中,我实现了进程数据页面的过滤、热度信息的收集以及与用户态程序的交互。这次的大作业加深了我对于Linux内核内存管理相关知识的理解,并且进一步提升了我的Linux内核编程能力,我受益匪浅。